SICOSE

Informe didáctico del modelo neuronal seleccionado

9 → 6 → 4
GSE + Mini-IPIP

Datos	200 casos | 140 entrenamiento / 30 validación / 30 prueba
Parámetros	78 pesos + 10 sesgos = 88
Modelo seleccionado	Semilla 31415 | mejores pesos: época 84
Resultado individual	20/30 coincidencias completas en prueba | 6 abstenciones
Destinatarios	Estudiantes de primeros años de universidad

17 de octubre de 2026

Explicación basada en el código y los artefactos guardados. Los datos fueron generados para ensayo. No acredita recomendaciones para personas reales.

Guía de lectura

Las primeras secciones explican qué recibe y produce la red. Las secciones 8 a 13 desarrollan los datos, el entrenamiento y la evaluación. El cierre reúne la selección de arquitectura, la trazabilidad y un glosario.

1. Qué hace el modelo y qué significa aprender . . . 3

2. Cómo leer la arquitectura 9 → 6 → 4 . . . 3

3. Las nueve entradas y su orden . . . 4

4. Normalización: poner las entradas en una escala común . . . 5

5. Pesos, sesgos y los 88 parámetros . . . 6

6. Funciones de activación . . . 6

7. Las cuatro salidas aprobadas . . . 7

8. Datos: qué representan los 200 ejemplos . . . 7

9. Separación de entrenamiento, validación y prueba . . . 8

10. Configuración del entrenamiento, explicada paso a paso . . . 9

11. Ejemplo numérico con el modelo guardado . . . 11

12. Resultados de la ejecución seleccionada . . . 12

13. Cómo se interpreta una salida y cuándo se abstiene . . . 13

14. Por qué se conserva una capa oculta de seis neuronas . . . 13

15. Parámetros aprendidos frente a hiperparámetros . . . 14

16. Guardado, reproducibilidad y trazabilidad . . . 15

17. Estado real, verificaciones y límites . . . 16

18. Glosario de consulta rápida . . . 16

19. Fuentes y correspondencia con la implementación . . . 17

Fecha de elaboración y verificación: 17 de octubre de 2026. Destinatarios: estudiantes de primeros años de universidad. Alcance: explicar la implementación y el entrenamiento existentes; no se modifica ni se vuelve a entrenar el modelo para elaborar este documento.

El modelo seleccionado es el archivo `output/modelo_gse_miniipip_200_20261017/modelo.json`, con semilla de pesos 31415 y mejores pesos de la época 84. Se conserva como experimento académico. Los 200 datos fueron generados artificialmente mediante reglas explícitas y no contienen información de instructores reales. En este informe se usa el rótulo «Datos» para mantener la presentación solicitada, sin cambiar su procedencia experimental.

1. Qué hace el modelo y qué significa aprender

Una red neuronal es una función matemática con números ajustables. Recibe valores de entrada, los combina y produce valores de salida. Aprender consiste en modificar esos números para que las salidas se aproximen a respuestas objetivo conocidas en los ejemplos de entrenamiento.

En este caso recibe nueve puntuaciones y produce cuatro activaciones asociadas a propuestas de acompañamiento. Es un problema de aprendizaje supervisado: cada ejemplo contiene entradas y cuatro etiquetas objetivo. Una etiqueta 1 indica que el generador propuso una salida; una etiqueta 0 indica que no la propuso.

Es también una clasificación multietiqueta: las cuatro salidas pueden combinarse. Un ejemplo puede tener el objetivo `[1, 0, 1, 0]`, que representa preparación y confianza junto con aprendizaje y autonomía. No es obligatorio elegir una sola categoría.

El entrenamiento realizado aprende a aproximar las reglas que generaron las etiquetas. No descubre por sí mismo qué recomendaciones son correctas para personas reales. La utilidad técnica del experimento consiste en estudiar el procesamiento, el aprendizaje, la evaluación y sus límites de forma reproducible.

2. Cómo leer la arquitectura 9 → 6 → 4

El número 9 representa las entradas; el 6, las neuronas de una capa oculta; y el 4, las neuronas de salida. Las flechas indican la dirección del cálculo. Es un perceptrón multicapa, abreviado MLP, de propagación hacia adelante: la información avanza desde las entradas hasta las salidas, sin ciclos ni memoria de eventos anteriores.

Parte	Cantidad	Función
Entradas	9	Presentar las puntuaciones normalizadas
Capa oculta	6 neuronas	Construir combinaciones no lineales de las nueve entradas
Capa de salida	4 neuronas	Producir una activación independiente por recomendación

La capa de entrada no aprende pesos propios. Hay dos transformaciones con parámetros aprendidos: entrada a capa oculta y capa oculta a salida. Por eso puede describirse como tres niveles de representación, pero tiene una sola capa oculta y dos capas de cálculo entrenables.

Las neuronas ocultas no tienen nombres psicológicos. No puede afirmarse que h1 mida confianza o que h2 mida colaboración: sus funciones surgen conjuntamente de los pesos aprendidos.



3. Las nueve entradas y su orden

El orden de las columnas forma parte del modelo. Intercambiar dos puntuaciones cambia el significado del cálculo aunque ambas estén en rangos válidos.

Posición	Entrada	Rango original	Significado previsto
x1	Físico	0 a 100	Promedio de las dos pruebas físicas
x2	Desempeño	0 a 100	Promedio de Jefe y Comandante
x3	Académica	0 a 100	Acumulado de cursos y operaciones con tope de 100
x4	GSE: autoeficacia	10 a 40	Puntuación global del cuestionario
x5	Mini-IPIP: extraversión	4 a 20	Dimensión de personalidad
x6	Mini-IPIP: amabilidad	4 a 20	Dimensión de personalidad

Posición	Entrada	Rango original	Significado previsto
x7	Mini-IPIP: responsabilidad	4 a 20	Dimensión de personalidad
x8	Mini-IPIP: neuroticismo	4 a 20	Dimensión de personalidad
x9	Mini-IPIP: apertura	4 a 20	Dimensión de personalidad

Las tres primeras entradas constituyen la evaluación institucional. Las seis restantes proceden de las pruebas psicométricas: una puntuación GSE y cinco de Mini-IPIP. Se conserva cada dimensión por separado; no se promedian las dos pruebas como una sola nota psicológica.

GSE tiene diez ítems y una puntuación global de autoeficacia percibida. Los autores no establecen un punto de corte universal. Mini-IPIP tiene veinte ítems, cuatro por dimensión; la representación elegida para este experimento usa cinco sumas de 4 a 20 después de corregir los ítems inversos. Documentación GSE, clave española Mini-IPIP.

El experimento utiliza puntuaciones agregadas posibles. No administra cuestionarios ni calcula estas sumas desde respuestas reales. Los significados institucionales describen el diseño de integración previsto, no una conexión activa con los expedientes del sistema. El neuroticismo se mantiene en su dirección original; no se renombra silenciosamente como estabilidad emocional.

4. Normalización: poner las entradas en una escala común

Normalizar es transformar números de diferentes rangos a una escala comparable. Aquí se utiliza el mínimo y máximo teóricos de cada entrada:

```
valor_normalizado = (valor_original - minimo) / (maximo - minimo)
```

Entrada de ejemplo	Operación	Valor normalizado
Físico = 75	(75 - 0) / (100 - 0)	0,75
GSE = 25	(25 - 10) / (40 - 10)	0,50
Responsabilidad = 12	(12 - 4) / (20 - 4)	0,50

Así, un 25 en GSE no se divide simplemente entre 40. Su mínimo es 10, y se debe restar antes de dividir. El mínimo de cada rango se transforma en 0 y el máximo en 1.

Esta transformación no convierte las puntuaciones en percentiles, diagnósticos ni porcentajes de aptitud. Un GSE normalizado de 0,50 significa que está a mitad de su rango posible; no que la persona tiene «50% de confianza».

Se usan rangos teóricos fijos y no mínimos o máximos aprendidos del conjunto de prueba. No hace falta ajustar un normalizador a esos 30 casos. Tampoco se recortan valores fuera de rango para que parezcan válidos: se rechazan.

El modelo exige nueve números finitos. Rechaza blancos, valores ausentes, NaN, infinito, booleanos y puntuaciones fuera de rango. No sustituye una prueba pendiente por cero; en particular, cero no es una puntuación válida de GSE ni de Mini-IPIP.

5. Pesos, sesgos y los 88 parámetros

Un peso controla cómo participa una señal en una combinación matemática. Un sesgo es un término adicional que permite desplazar esa combinación sin depender de una entrada particular. Ambos se ajustan durante el entrenamiento.

Componente	Dimensión	Cantidad de parámetros
W1: pesos de entradas a capa oculta	6 filas por 9 columnas	54
b1: sesgos de capa oculta	6 valores	6
W2: pesos de capa oculta a salidas	4 filas por 6 columnas	24
b2: sesgos de salida	4 valores	4
Total	78 pesos y 10 sesgos	88

La operación de una neurona empieza con una suma ponderada. Por ejemplo, para la neurona oculta h1:

```
z1 = w11*x1 + w12*x2 + ... + w19*x9 + b1
h1 = tanh(z1)
```

Los pesos no son porcentajes de importancia ni tienen que sumar 1. Pueden ser negativos y superar el rango de inicialización después de aprender. El signo de un peso individual tampoco basta para afirmar una relación causal con la recomendación final: existen otras conexiones y una transformación no lineal intermedia.

Los seis valores ocultos alimentan cada salida. Todas las entradas se conectan con todas las neuronas ocultas y todas las ocultas con todas las salidas; esto se llama conexión densa o completa.

6. Funciones de activación

Una función de activación transforma la suma que recibe una neurona. Introduce relaciones no lineales; sin ella, encadenar transformaciones lineales seguiría siendo equivalente a una sola transformación lineal.

6.1 Capa oculta: tangente hiperbólica, tanh

La capa oculta aplica tanh a cada una de sus seis sumas. Su salida se encuentra entre -1 y 1. Cerca de cero cambia con rapidez y, para valores muy positivos o negativos, se aproxima gradualmente a los extremos.

```
tanh(0) = 0
tanh(1) ≈ 0,7616
tanh(-1) ≈ -0,7616
```

Esta función permite combinar señales con efectos positivos o negativos y es derivable, propiedad necesaria para calcular cómo ajustar los pesos. Es una elección aplicada en este experimento; no se demostró que sea la mejor activación para este problema.

6.2 Capa de salida: sigmoide

Cada salida usa una sigmoide independiente:

```
sigmoide(z) = 1 / (1 + exp(-z))
```

Devuelve un valor entre 0 y 1. Por ejemplo, con z = 0 devuelve 0,5 y con z = 2 devuelve aproximadamente 0,8808. Las cuatro activaciones no deben sumar 1 porque las recomendaciones pueden coexistir.

Se eligieron cuatro sigmoides, no una función softmax que obligue a competir entre categorías. Las activaciones sirven para aplicar los umbrales del experimento; no están calibradas como probabilidades reales de necesidad de apoyo.

Para estabilidad numérica, el código limita el argumento usado por la exponencial al intervalo [-40, 40]. La pérdida utiliza un mínimo de 0,000000000001 antes de tomar logaritmos. Son protecciones aritméticas, no reglas psicométricas.

7. Las cuatro salidas aprobadas

Salida	Nombre	Tipo de propuesta
y1	Preparación y confianza	Preparación física progresiva, metas alcanzables, hábitos y reconocimiento de avances
y2	Comunicación y colaboración	Coordinación, participación gradual y retroalimentación individual
y3	Aprendizaje y autonomía	Capacitación práctica, objetivos de aprendizaje y seguimiento
y4	Afrontamiento y metas	Orientación voluntaria sobre exigencias, organización de metas y estrategias de afrontamiento

Los nombres corresponden a categorías de acompañamiento propuestas y aprobadas para el prototipo. El texto asociado se recupera de una lista fija: el modelo no redacta libremente como un modelo de lenguaje ni produce un diagnóstico.

La salida numérica tiene cuatro posiciones, por ejemplo `[0,82; 0,14; 0,76; 0,09]`. Este ejemplo ilustra el formato y no corresponde a una predicción sobre una persona. Después se aplica una regla de lectura, explicada en la sección 13.

8. Datos: qué representan los 200 ejemplos

Cada fila contiene identificador, procedencia, partición, nueve entradas y cuatro etiquetas. Los identificadores numeran ejemplos de laboratorio; no corresponden a personas ni son entradas del modelo.

El generador propone Físico y Desempeño entre 0 y 100 en incrementos de 0,5; Académica entre 0 y 100 en enteros; GSE entre 10 y 40 en enteros; y cada dimensión Mini-IPIP entre 4 y 20 en enteros. Se simulan sumas posibles, sin generar las respuestas individuales de los cuestionarios.

Primero se proponen valores con muestreo uniforme independiente. Luego se aceptan o rechazan según la combinación objetivo que se necesita completar. Por tanto, el conjunto finalmente aceptado está condicionado por las reglas y el equilibrio de etiquetas; no se puede afirmar que conserve independencia o distribución uniforme poblacional.

Hay 16 combinaciones posibles de cuatro etiquetas binarias, porque 2 elevado a 4 es 16. Todas aparecen en cada partición. Las filas de entrada son únicas, sin duplicados entre particiones. Cada salida tiene 100 etiquetas positivas y 100 negativas en los 200 datos; ese equilibrio se construyó deliberadamente y no representa prevalencias reales.

8.1 Reglas utilizadas para asignar etiquetas

Las siguientes expresiones son hipótesis didácticas inventadas. No son baremos de GSE o Mini-IPIP ni criterios institucionales de evaluación. Sus coeficientes se eligieron para construir un problema de aprendizaje, no se estimaron a partir de decisiones profesionales.

Para leerlas, F es Físico, D es Desempeño, Ac es Académica, G es GSE, E es extraversión, A es amabilidad, C es responsabilidad, N es neuroticismo y O es apertura. Todas estas letras representan valores normalizados entre 0 y 1.

```
y1_objetivo = 1 si:
F < 0,60 y 0,70*(1-F) + 0,20*(1-G) + 0,10*(1-C) > 0,42

y2_objetivo = 1 si:
D < 0,60 y 0,65*(1-D) + 0,20*(1-G)
            + 0,075*(1-E) + 0,075*(1-A) > 0,42

y3_objetivo = 1 si:
Ac < 0,60 y 0,65*(1-Ac) + 0,20*(1-G)
             + 0,075*(1-O) + 0,075*(1-C) > 0,42

y4_objetivo = 1 si:
G < 0,50 y 0,65*(1-G) + 0,20*N + 0,15*(1-C) > 0,50

Si no se cumplen las condiciones de una salida, su etiqueta es 0.
```

Por ejemplo, con F = 0,40, G = 0,50 y C = 0,50, la suma de la primera regla es 0,42 + 0,10 + 0,05 = 0,57. Como F < 0,60 y 0,57 > 0,42, el generador asigna y1 = 1.

Las primeras tres reglas requieren una nota institucional inferior a 60; un rasgo de personalidad por sí solo no activa esas etiquetas. La cuarta exige además G < 0,50, equivalente a GSE < 25. Este último corte es inventado para el ensayo: no debe presentarse como un umbral oficial de autoeficacia.

Es importante reconocer una limitación del diseño: aunque ningún rasgo aislado basta, las reglas sí hacen que determinados rasgos modifiquen las etiquetas en casos cercanos al límite. Esa relación no está validada y requeriría revisión antes de cualquier uso con personas. Entrenar una red para reproducirla no la convierte en evidencia científica.

9. Separación de entrenamiento, validación y prueba

Partición	Casos	Proporción	Para qué se usa
Entrenamiento	140	70%	Calcular el error y modificar pesos y sesgos
Validación	30	15%	Elegir la mejor época y decidir cuándo detenerse
Prueba	30	15%	Describir el resultado después de elegir los pesos

Una analogía útil es estudiar con ejercicios, comprobar el progreso con un simulacro y realizar una evaluación final. Los tres conjuntos tienen funciones distintas. La validación no realiza actualizaciones de pesos, pero sí influye en qué versión se conserva. Por eso no equivale a un conjunto independiente para la evaluación final.

Cada salida tiene 70 positivos y 70 negativos en entrenamiento, y 15 positivos y 15 negativos tanto en validación como en prueba. Las particiones se fijan antes del entrenamiento; el código rechaza entrenamiento o validación con etiquetas de partición incorrectas y detecta solapamientos entre ambos conjuntos.

La prueba no se utilizó para elegir la época 84. Sin embargo, esos mismos 30 casos se han consultado después en comparaciones de arquitecturas. Desde ese momento, los resultados comparativos son exploratorios; no debe llamarse a esa prueba una evaluación nueva e independiente de todas las decisiones de diseño.

10. Configuración del entrenamiento, explicada paso a paso

10.1 Inicialización y semillas

Antes de aprender, los pesos se generan con distribución uniforme entre -0,5 y 0,5. Los diez sesgos comienzan en cero. Dar pesos iniciales diferentes permite que las neuronas empiecen a construir combinaciones distintas.

Una semilla es el número que inicia un generador pseudoaleatorio. Permite repetir una secuencia de elecciones. Se usan tres semillas independientes:

Semilla	Valor	Función
Datos	2718	Generación, aceptación de ejemplos y mezcla final de filas
Pesos	31415	Inicialización de las conexiones del modelo seleccionado
Orden	42	Barajado del entrenamiento en cada época

La semilla no es una puntuación de calidad. Cambiarla puede cambiar el resultado, pero elegirla por su acierto en prueba introduciría una selección favorable a esa prueba. El modelo seleccionado conserva la semilla 31415; no fue reemplazado por la mejor de las diez inicializaciones posteriores.

10.2 Función de pérdida: entropía cruzada binaria

La pérdida mide cuánto difieren las activaciones de las etiquetas objetivo. Para una salida, con objetivo t y activación p:

```
error = -[t*ln(p) + (1-t)*ln(1-p)]
```

Si el objetivo es 1, una activación 0,9 produce un error aproximado de 0,1053; una activación 0,1 produce 2,3026. Equivocarse con una activación muy extrema recibe una penalización considerable.

En cada ejemplo se suman los errores de las cuatro salidas. Para informar la pérdida de una partición se promedian esas sumas entre sus ejemplos. No se divide además entre cuatro: una implementación que lo hiciera reportaría números distintos aun con las mismas predicciones.

Una pérdida menor indica mejor ajuste a las etiquetas del experimento. No es un porcentaje de error ni una medida de salud o aptitud. La coincidencia binaria puede empatar y la pérdida diferir, porque esta última también considera los valores de las activaciones.

10.3 Retropropagación y gradiente

Un gradiente indica cómo cambiaría el error al modificar ligeramente un parámetro. La retropropagación aplica la regla de la cadena para calcularlo desde las salidas hacia las capas anteriores.

Con sigmoide y entropía cruzada, el término de error de salida es p - t. Para la capa oculta se combina ese error con los pesos de salida y con la derivada de tanh, que es $1 - h^2$. El código calcula estos términos antes de modificar las matrices, para que una actualización no altere indebidamente el cálculo de otra.

Se verifica matemáticamente comparando los gradientes calculados con pequeñas perturbaciones numéricas de los parámetros. Esta prueba comprueba el algoritmo, pero no valida el significado de las etiquetas.

10.4 Optimizador SGD y tamaño de lote

SGD significa descenso de gradiente estocástico. «Descenso» indica que se avanza en una dirección que busca reducir el error. «Estocástico» hace referencia al uso de ejemplos individuales en un orden barajado.

El tamaño de lote es 1: se actualizan los parámetros después de cada ejemplo de entrenamiento. No se espera a procesar los 140 para actualizar una sola vez. Tampoco se utilizan Adam, momentum o lotes mayores en esta implementación.

10.5 Tasa de aprendizaje: 0,03

La tasa de aprendizaje controla el tamaño del ajuste. Sin regularización, una actualización ilustrativa sería:

```
peso_nuevo = peso_anterior - 0,03 * gradiente
```

Si el peso es 0,50 y su gradiente 0,20, se obtiene 0,494. Una tasa excesiva puede producir cambios inestables; una muy pequeña puede hacer el avance lento. Aquí se usa 0,03 constante, sin programación automática de reducción. No se realizó una búsqueda que demostrara que es la tasa óptima.

10.6 Regularización L2: 0,001

Regularizar consiste en añadir una preferencia por soluciones menos extremas. L2 penaliza el cuadrado de los pesos. En la actualización aplicada:

```
peso_nuevo = peso_anterior - 0,03 * (gradiente + 0,001*peso_anterior)
```

El término adicional tiende a reducir la magnitud del peso, salvo que el error de los ejemplos justifique compensarlo. Por ejemplo, con peso 0,50 y gradiente 0,20, resulta 0,493985 al incluir L2.

L2 se aplica a las matrices W1 y W2, no a los sesgos. La pérdida reportada y usada para elegir la época es la entropía cruzada de validación sin sumar la penalización L2. La regularización puede ayudar a controlar el ajuste excesivo, pero no lo elimina ni compensa la ausencia de ejemplos reales.

10.7 Épocas, máximo y parada temprana

Una época es una pasada completa por los 140 ejemplos de entrenamiento. El máximo configurado es 300 épocas. En cada época se vuelve a barajar el orden con la secuencia reproducible de semilla 42.

Después de cada época se calcula la pérdida de validación. Si disminuye en más de 0,000001 respecto de la mejor guardada, se conserva una copia de todos los pesos y sesgos y se reinicia el contador de espera. Esa pequeña tolerancia evita considerar como mejora diferencias numéricas insignificantes.

La paciencia es 25: se detiene el entrenamiento después de 25 épocas consecutivas sin una mejora suficiente. En la ejecución seleccionada:

Configuración o resultado	Valor
Máximo permitido	300 épocas
Mejor época encontrada	84
Épocas ejecutadas	109
Épocas posteriores sin mejora suficiente	25

Configuración o resultado	Valor
Pesos finalmente guardados	Los de la época 84

Se realizaron 109 × 140 = 15.260 actualizaciones durante la ejecución. Al terminar se restauró el punto de control de la época 84; no se utilizaron los pesos de la época 109 para el modelo seleccionado. Hasta el punto restaurado se habían realizado 84 × 140 = 11.760 actualizaciones.

El archivo conserva los parámetros finales y el resumen de entrenamiento, pero no una curva completa por época. Por ello este informe no inventa una trayectoria de pérdida ni asegura que el error de entrenamiento aumentó o disminuyó en una época concreta no registrada.

11. Ejemplo numérico con el modelo guardado

El siguiente recorrido se calcula directamente a partir de una fila del CSV y de los pesos conservados. Es un ejemplo experimental, no un expediente personal ni una recomendación aplicada.

Fila experimental elegida: ID 171, partición de prueba. No se seleccionó por un resultado favorable.

Entrada	Original	Normalizada
fisica	66.5	0,665000
desempeno	39	0,390000
academica	8	0,080000
gse_autoeficacia	24	0,466667
mini_extraversion	4	0,000000
mini_amabilidad	11	0,437500
mini_responsabilidad	8	0,250000
mini_neuroticismo	18	0,875000
mini_apertura	5	0,062500

Para h1, los nueve pesos aprendidos son:

```
[-0,083759; -0,205878; 0,513477; -5,383244; 0,354495; 0,135349; -0,205579; 0,184466; -0,209806]
Sesgo b1[0] = 1,921216
Suma z1 = -0,529764
h1 = tanh(z1) = -0,485201
```

Las seis activaciones ocultas calculadas son:

```
[-0,485201; 0,559609; 0,427280; 0,432400; 0,989863; -0,277400]
```

Salida	Suma antes de sigmoide	Activación	Objetivo
preparacion_y_confianza	-0,584988	0,357786	0
comunicacion_y_colaboracion	5,351353	0,995281	1
aprendizaje_y_autonomia	6,979931	0,999070	1

Salida	Suma antes de sigmoide	Activación	Objetivo
afrontamiento_y_metas	-2,194163	0,100276	1

Estado de la simulación: ABSTENCION. Texto devuelto: Resultado indeterminado: requiere revisión humana.

Observe la diferencia entre etiqueta objetivo y activación. La etiqueta procede de la regla generadora; la activación procede de los pesos de la red. Pueden diferir porque el modelo aproxima las reglas, sin reproducirlas exactamente en todos los casos.

12. Resultados de la ejecución seleccionada

Estas métricas corresponden exclusivamente al archivo con semilla 31415, mejor época 84, no al promedio de varias redes.

Partición	Casos	Coincidencia completa	Pérdida	Abstenciones
entrenamiento	140	129/140 = 92.14%	0.253423	14
validacion	30	26/30 = 86.67%	0.385394	3
prueba	30	20/30 = 66.67%	0.589899	6

12.1 Coincidencia completa y coincidencia por salida

La coincidencia completa exige acertar las cuatro etiquetas del mismo caso al aplicar un umbral de 0,5. En prueba se acertaron simultáneamente en 20 de 30 casos: 66,67%. Si se falló una sola etiqueta, el caso ya no cuenta como coincidencia completa.

La coincidencia por salida cuenta cada recomendación por separado. Por eso sus porcentajes pueden ser mayores que la coincidencia completa. No deben promediarse y presentarse como si fueran el mismo indicador.

Salida en prueba	Coincidencia	VP	VN	FP	FN	F1
preparacion y confianza	86.67%	15	11	4	0	0.8824
comunicacion y colaboracion	96.67%	14	15	0	1	0.9655
aprendizaje y autonomia	90.00%	14	13	2	1	0.9032
afrontamiento y metas	93.33%	13	15	0	2	0.9286

VP significa verdadero positivo: se activó una etiqueta que tenía objetivo 1. VN es verdadero negativo: se dejó en 0 una etiqueta que tenía objetivo 0. FP es falso positivo y FN es falso negativo. Aquí «verdadero» significa coincidencia con la etiqueta artificial del ejemplo, no certeza sobre necesidades humanas.

12.2 Qué significa F1

F1 combina precisión positiva y sensibilidad. La precisión positiva pregunta cuántas activaciones fueron correctas entre todas las predicciones positivas. La sensibilidad pregunta cuántos objetivos positivos se recuperaron. Una forma equivalente de calcular F1 es:

```
F1 = 2*VP / (2*VP + FP + FN)
```

Para preparación y confianza, VP = 15, FP = 4 y FN = 0. Así, F1 = 30/34 = 0,8824. No cuenta los verdaderos negativos y no debe llamarse «88,24% de recomendaciones válidas».

12.3 Tamaño de prueba y alcance

Un caso cambia la coincidencia completa de prueba en aproximadamente 3,33 puntos porcentuales, porque solo hay 30 casos. El resultado es sensible al conjunto utilizado. Tampoco una buena coincidencia demuestra que la regla generadora sea adecuada fuera del laboratorio.

13. Cómo se interpreta una salida y cuándo se abstiene

Para las métricas anteriores se usa 0,5. Para convertir activaciones en textos de simulación se aplica una regla distinta:

Activación	Lectura de esa salida
Menor o igual a 0,35	Inactiva
Mayor o igual a 0,65	Activa
Estrictamente entre 0,35 y 0,65	Incierta

Si cualquiera de las cuatro salidas es incierta, el sistema se abstiene globalmente y devuelve «Resultado indeterminado: requiere revisión humana». Esa respuesta sustituye las sugerencias parciales que pudieran haber superado 0,65. Los valores exactos 0,35 y 0,65 no pertenecen a la zona incierta.

Si no hay incertidumbre y ninguna salida se activa, devuelve seguimiento y oportunidades generales de desarrollo. Si varias se activan sin incertidumbre en las demás, muestra los textos correspondientes a todas ellas.

Ejemplos ilustrativos, no calculados para personas:

Vector de activaciones	Resultado de la regla de lectura
[0,82; 0,14; 0,76; 0,09]	Activa y1 e y3
[0,82; 0,50; 0,76; 0,09]	Abstención global por y2 incierta
[0,10; 0,20; 0,15; 0,30]	Seguimiento general

En prueba hubo seis abstenciones de treinta casos, es decir 20%. Los otros 24 casos no tuvieron activaciones intermedias; eso no significa que los 24 fueran correctos. La abstención y la coincidencia completa se calculan por separado y no son porcentajes complementarios.

Los umbrales 0,35 y 0,65 son decisiones experimentales. No están calibrados con resultados humanos ni garantizan un nivel de seguridad o confianza. Una activación 0,80 no significa automáticamente «80% de probabilidad de necesitar apoyo».

14. Por qué se conserva una capa oculta de seis neuronas

La arquitectura de seis neuronas es una base compacta: tiene 88 parámetros y permite estudiar relaciones no lineales sin aumentar innecesariamente el tamaño. La elección es una decisión de diseño del prototipo, no el resultado de demostrar que seis es el número óptimo universal.

Se comparó con 9 → 6 → 4 → 4 usando el mismo CSV GSE/Mini-IPIP, diez semillas por arquitectura y el mismo protocolo. El criterio principal definido antes de interpretar resultados fue la menor pérdida media de validación.

Medida media entre diez inicializaciones	9 → 6 → 4	9 → 6 → 4 → 4
Parámetros	88	108
Pérdida de validación	0,4036	0,4830
Coincidencia completa de prueba	74,67%	69,67%

Este ensayo favoreció conservar la arquitectura actual bajo ese protocolo. No prueba que todas las redes con dos capas sean peores ni que no puedan mejorar con otro diseño debidamente evaluado. No se hizo una búsqueda de hiperparámetros específica para cada arquitectura.

El 74,67% es un promedio de diez inicializaciones de la arquitectura; el 66,67% corresponde al modelo individual guardado. No se debe reemplazar una cifra por la otra. Las diez semillas no multiplican el conjunto de datos ni crean diez muestras independientes de personas.

Las comparaciones anteriores con DASS-21 y CBI pertenecen a otro problema de entradas y etiquetas. Sus porcentajes no se utilizan como resultados de este modelo GSE/Mini-IPIP. La alternativa 9 → 8 → 4 → 4 no se ha evaluado con estos datos nuevos.

15. Parámetros aprendidos frente a hiperparámetros

Un parámetro se aprende durante el entrenamiento: un peso o un sesgo. Un hiperparámetro se fija para organizarlo: la cantidad de neuronas, la tasa o la paciencia. Un valor aprendido no equivale a una decisión profesional interpretada por el sistema.

Configuración	Valor aplicado	Tipo o finalidad
Arquitectura	9 → 6 → 4	Hiperparámetro de estructura
Pesos y sesgos	88 valores	Parámetros aprendidos
Activación oculta	tanh	Transformación no lineal
Activación de salida	Cuatro sigmoides	Salidas combinables
Normalización	Mínimos y máximos teóricos	Preprocesamiento fijo
Optimizador	SGD	Método de actualización
Lote	1 ejemplo	Actualización por ejemplo
Tasa	0,03 constante	Tamaño del paso
Regularización	L2 = 0,001	Penalización de pesos, no sesgos
Pérdida	Entropía cruzada binaria	Suma de cuatro salidas, media por caso
Épocas máximas	300	Límite de entrenamiento
Paciencia	25	Parada sin mejora de validación
Mejora mínima	Más de 0,000001	Tolerancia de selección

Configuración	Valor aplicado	Tipo o finalidad
Mejor época	84	Resultado observado
Épocas ejecutadas	109	Resultado observado
Umbral para métricas	0,5	Binarización para evaluación
Umbrales para simulación	0,35 y 0,65	Lectura con abstención

No se aplican dropout, normalización por lotes, momentum, ajuste automático de tasa, selección automática de variables o búsqueda automática de arquitectura. Son características del código inspeccionado; su ausencia no demuestra por sí sola una carencia o una ventaja.

16. Guardado, reproducibilidad y trazabilidad

El motor está escrito con la biblioteca estándar de Python. No utiliza TensorFlow, PyTorch ni un servicio externo para entrenar. Los pesos se guardan como números en JSON, con arquitectura, entradas, rangos, activaciones y metadatos de entrenamiento.

Archivo	Contenido
modelo.json	Los 88 valores aprendidos, estructura y configuración
informe.json	Protocolo, reglas, métricas y resumen del entrenamiento
datos_sinteticos.csv	Los 200 datos y sus particiones originales
predicciones.csv	Etiquetas, activaciones y estado para auditar cada ejemplo
manifest.json	Huellas SHA-256 de los cuatro archivos anteriores

SHA-256 produce una huella de los bytes de un archivo. Si cambia el archivo, normalmente cambia su huella. Permite detectar modificaciones respecto del manifiesto; no certifica la validez científica ni reemplaza una firma institucional.

Huellas verificadas de los artefactos principales:

```
modelo.json
abb2bed7e4bcc7e232388bf671afbf5d2ba5bce309f14b79026d92a2d0bad252

datos_sinteticos.csv
b092c954c6580180b517af7dfaaaf1dbc29a99d7428dcbb00fea420693be499d
```

Para repetir el entrenamiento se debe usar una carpeta nueva, conservando el entorno y los artefactos existentes:

```
.venv\Scripts\python.exe scripts\entrenar_red_gse_miniipip.py --salida output\replica_gse_964
```

El comando anterior sí inicia un entrenamiento nuevo; no fue necesario ejecutarlo para elaborar este informe. Mantener semillas, código, orden de columnas, datos y entorno permite verificar la reproducción. No se deben eliminar ni sobrescribir los archivos del modelo seleccionado para hacer una prueba.

17. Estado real, verificaciones y límites

El modelo está entrenado para simulación offline. No está conectado a las rutas de instructores ni produce recomendaciones en sus expedientes. No se han habilitado cuestionarios oficiales GSE/Mini-IPIP mediante esta entrega y no se ha alterado la base SQLite para elaborar el informe.

Las pruebas técnicas existentes comprueban rangos, distribución, ausencia de solapamientos, gradientes numéricos, restauración de mejores pesos, archivos guardados y conservación de modelos previos. Estas comprobaciones aportan evidencia sobre el software. No evalúan la idoneidad psicológica de una recomendación ni la aceptación institucional.

El conjunto pequeño, sus reglas artificiales, el equilibrio construido y la falta de etiquetas profesionales independientes limitan la generalización. La revisión de los objetivos es necesaria para evitar que los rasgos de personalidad se conviertan en juicios no justificados sobre desempeño o necesidades de apoyo.

Para estudiar un uso posterior con personas harían falta objetivos acordados, datos autorizados y representativos, revisión de pertinencia de instrumentos, recomendaciones humanas de referencia, evaluación independiente, análisis de errores y sesgos, calibración y reglas de seguimiento. Es trabajo pendiente; no se presume resuelto por haber entrenado o seleccionado una arquitectura.

El alcance acordado sigue siendo orientación y referencia, sin diagnóstico ni decisiones automáticas de ascenso, sanción o aptitud operativa. Aprobar nombres de salidas no valida las reglas que relacionan las puntuaciones con esas salidas.

18. Glosario de consulta rápida

Concepto	Explicación sencilla
Entrada o característica	Número que se entrega a la red
Etiqueta objetivo	Respuesta que se intenta aprender en un ejemplo
Neurona	Suma ponderada seguida de una transformación
Peso	Número aprendido que multiplica una señal
Sesgo	Número aprendido que desplaza una suma
Activación	Resultado de la transformación de una neurona
Capa oculta	Transformación intermedia entre entradas y salidas
Multietiqueta	Permite varias salidas activas a la vez
Pérdida	Medida numérica del desacuerdo con los objetivos
Gradiente	Indicación matemática de cómo cambiar un parámetro
Retropropagación	Cálculo del gradiente a través de las capas
Época	Una pasada por los ejemplos de entrenamiento
Sobreajuste	Ajustarse a particularidades del entrenamiento que no se mantienen fuera de él
Regularización	Preferencia añadida para controlar soluciones demasiado extremas
Validación	Datos usados para elegir cómo o cuándo conservar el modelo
Prueba	Datos usados para evaluar después de esa elección
Abstención	Decisión de no emitir sugerencias por incertidumbre definida
Calibración	Correspondencia comprobada entre puntuaciones y frecuencias observadas

19. Fuentes y correspondencia con la implementación

Las cifras de esta versión se verifican contra archivos locales, no contra estimaciones de conversaciones previas. El conjunto de fuentes principales es:

• `sicose/red_gse_miniipip.py`: orden y rangos, normalización, generación, reglas y salidas.

• `sicose/red_experimental.py`: cálculo hacia adelante, SGD, regularización, pérdida, parada y abstención.

• `scripts/entrenar_red_gse_miniipip.py`: configuración efectiva de la ejecución, particiones y guardado.

• `output/modelo_gse_miniipip_200_20261017/modelo.json`, `informe.json` y `manifest.json`: valores de la ejecución seleccionada e integridad.

• `output/comparacion_gse_miniipip_9644_200_20261017/comparacion.json`: comparación actual de diez inicializaciones.

• GSE, documentación de los autores: puntuación y ausencia de corte universal.

• Mini-IPIP, clave española del IPIP: dimensiones y corrección de ítems inversos.

Las explicaciones de pesos, activaciones y entrenamiento describen las operaciones del código inspeccionado. Las reglas didácticas son propias del experimento y no se atribuyen a los autores de los instrumentos.